

JEV-1.13 高中美国历史测试报告

2026 年 9 月 28 日

摘要

本报告记录模型 JEV-1.13 在 MMLU 基准高中美国历史科目上的测试结果。测试共 188 道四选一单选题，模型答对 180 道，准确率 95.7%，远高于 25% 的随机水平。模型为每题给出各选项的概率，其中所选选项的概率下称所选概率：该概率为 1.00 的 134 题几乎全对（99.3%），低于 1.00 的 54 题准确率为 87.0%。整次测试消耗输入 122 404 token、输出 8 460 token，总费用 0.0051 美元。在该场景下，模型答题准确、代价极低，其给出的概率能标示答案的可靠程度。

1 数据集

数据来自 MMLU (Massive Multitask Language Understanding) 基准的高中美国历史科目测试集 [1]。测试共 188 题，均为四选一单选题。每题由一段材料（文献引文或情境描述）和一个设问构成，模型需选出唯一正确选项。标准答案由数据集提供，在四个选项字母上的分布接近均匀（A 47 题、B 42 题、C 51 题、D 48 题）。被测对象为模型 JEV-1.13（标识 typesafe/jev-1.13-20260917）。

2 结果

以下结果均以数据集提供的标准答案为判据。

2.1 整体结果

表 1 给出整体结果。188 题中模型答对 180 题，准确率 95.7%（95% 置信区间 91.8%–97.8%）。四选一题随机猜测的期望准确率为 25%，模型的成绩远高于该水平。

2.2 所选概率与准确率

除所选答案外，模型还给出每题四个选项各自的概率；取其中所选选项的概率，记为所选概率。

134 题（71.3%）的所选概率为 1.00，其中 99.3% 答对；其余 54 题低于 1.00，准确率为 87.0%。180 道

表 1: 整体结果

项目	数值
题目数	188
答对题数	180
准确率	95.7%
95% 置信区间	91.8%–97.8%

答对题的平均所选概率为 0.99，8 道答错题的平均所选概率为 0.83。

图 1 按所选概率分档给出题目数与准确率。低于 0.90 的 7 题中仅 4 题答对；各档准确率随所选概率总体上升，0.99 档与 1.00 档均超过 99%。所选概率能区分答案的可靠程度，可作为判断单题答案可信与否的参考。




图 1: 按所选概率分档的题目数与准确率。柱高为该档题目数，蓝色为答对、红色为答错，柱顶百分比为该档准确率。

2.3 调用成本

如表 2 所示，整次测试消耗输入 122 404 token、输出 8 460 token，总费用 0.0051 美元。

表 2: 调用成本

项目	数量
输入 token	122 404
输出 token	8 460
总费用	0.0051 美元

3 结论

在 188 道高中美国历史四选一题上, JEV-1.13 答对 180 道, 准确率 95.7%, 远高于随机水平; 七成以

上的题所选概率为 1.00, 且几乎全对, 而所选概率低于 0.90 的题不足六成答对。整次测试总费用约半美分。综合看, JEV-1.13 在该场景下答题准确、代价极低, 其给出的所选概率可用于识别不可靠的答案。

参考文献

- [1] Dan Hendrycks, Collin Burns, Steven Basart, Andrew Critch, Jerry Li, Dawn Song, Jacob Steinhardt. *Measuring Massive Multitask Understanding*. ICLR 2021. 数据取自 [cais/mmlu](https://openai.com/research/evaluating-gpt-4-on-mmlu) 测试集。